

NOTA METODOLOGICA: MODELO DE PREVISAO PRESIDENCIAL 2026

Desafio de Estatística e Econometria FGV EPGE | Grupo: Joao Pedro Valuche, Arthur Caron Lyra, Lethicia Manfioletti Possamai | Tag: modelo-congelado

1. Dados, Fontes e Pre-processamento

A base do projeto congrega pesquisas de intencao de voto registradas no sistema PesqEle/TSE conduzidas por institutos nacionais de primeira linha (Datafolha, Quaest, AtlasIntel, PoderData e Real Time Big Data). O pre-processamento segue estritamente tres regras: (i) **Filtro de Vespera e Corte**: levantamentos na janela de tres semanas anteriores ao pleito, com corte as 20h00 de sabado (03/10/2026); (ii) **Conversao para Validos**: exclusao de votos brancos, nulos e indecisos com renormalizacao a 100,0% ($p_{i,j} = v_{i,j} / \sum_k v_{k,j} \times 100\%$) para os 12 candidatos oficiais do edital; (iii) **Arredondamento**: aplicacao do algoritmo de Maiores Restos (Hamilton-Hare) na entrega em uma casa decimal, garantindo soma exata de 100,0%.

2. Formulacao Formal dos Modelos Base (M0 a M3)

- M0 (Media Simples por Instituto)**: $p_hat_i^{M0} = (1/J) \sum_{j=1}^J p_{i,j}$ (agrega a ultima pesquisa valida de cada instituto na vespera).
- M1 (Decaimento Temporal Exponencial)**: $p_hat_i^{M1} = \sum w_j p_{i,j} / \sum w_j$, com $w_j = \exp(-\ln(2) * dt_j / h)$, testado para meia-vida h em {7, 14, 21} dias.
- M2 (Efeito de Casa com Regularizacao Shrinkage)**: $p_hat_i^{M2} = \sum w_j (p_{i,j} - beta_hat_{i,inst})$, com $beta_hat_{i,inst} = [n_{inst} / (n_{inst} + k)] \Delta_bar_{i,inst}$, k em {1, 3, 10}.
- M3 (Regressao Ridge com Incumbencia)**: $p_hat_i^{M3} = x_i' beta_hat$, regularizado com penalidade L2 (alpha em {0.01, 0.1, 1.0, 10.0}) incluindo variavel binaria de governismo.

3. Backtest Historico e Selecao de Modelos (Expanding Window)

O backtest avaliou causalmente as eleicoes de 2014, 2018 e 2022 (treino restrito a t-1; total de 11 a 13 candidatos da urna oficial apurada pelo TSE). A metrica primaria e o Mean Absolute Error (MAE) sobre todos os concorrentes da urna:

Modelo Avaliado	2014 (p.p.)	2018 (p.p.)	2022 (p.p.)	Media Exp.	Decisao pela Regra Pre-registrada
M0 Puro	1,3317	1,4964	0,8341	1,2207	VENCEDOR ETAPA 1 (Menor Erro e Parcimonia)
M1 (h=7d)	1,4898	2,0585	0,9151	1,4878	Rejeitado (MAE superior ao M0)
M1 (h=14d)	1,5142	2,0585	0,9151	1,4959	Rejeitado (MAE superior ao M0)
M2 (k=1)	1,4890	2,0601	0,9180	1,4890	Rejeitado (MAE superior ao M0)
M2 (k=3)	1,5004	2,0594	0,9167	1,4922	Rejeitado (MAE superior ao M0)
M2 (k=10)	1,5098	2,0588	0,9156	1,4947	Rejeitado (MAE superior ao M0)
M3 (alpha=0.1)	1,4954	2,0585	0,9151	1,4897	Rejeitado (MAE superior ao M0)
M3 (alpha=1.0)	1,5078	2,0585	0,9151	1,4938	Rejeitado (MAE superior ao M0)

Ajustes da Etapa 2 Incorporados e Rejeitados sobre o M0:

- Vies Comum de Pesquisa (k_mu=3): APROVADO.** Corrige a subestimacao sistematica de votos do principal adversario do PT observada nas vespersas. Reduz o MAE medio em **0,1834 p.p.**, superando com folga o limiar estatistico de 1 SE ($\Delta_bar > SE = 0,1026$ p.p.).
- Voto Util Estrategico (gamma=1.0): APROVADO.** Modela a migracao dos eleitores do 3o e 4o colocados para os dois ponteiros na reta final. Reduz o MAE em **0,1301 p.p.** ($\Delta_bar > SE = 0,0889$ p.p.), derrubando o erro de 2022 para 0,5284 p.p.
- Efeito de Casa (M2): REJEITADO.** Na vespera imediata, as divergencias entre institutos refletem primariamente variancia amostral; o shrinkage nao superou M0.
- Prior de Nanicos (w=0.5): REJEITADO PELA REGRA FORMAL.** Testado causalmente por partido historico. Obteve ganho de apenas $\Delta_bar = 0,0040$ p.p. com $SE = 0,0067$ p.p. Como $\Delta_bar \leq SE$, o efeito e indistinguivel de zero (limitacao estrutural das pesquisas historicas que agregavam nanicos em 'outros'). Fixa-se compulsoriamente **w=0.0 no Modelo Oficial**, retendo w=0.5 apenas para analise de sensibilidade.
- Modelo Oficial Aprovado:** M0 + Vies Comum (k=3) + Voto Util (gamma=1.0) com w=0.0. O MAE medio despenca para **0,9640 p.p.**, com reducao consolidada de **0,2568 p.p.** ($> 6 \times SE$).

4. Analise de Sensibilidade, Moderacao da Margem e Limitacao Honesta

Confronto Preliminar 2026 (Lula x Flavio Bolsonaro):

- **M0 Puro:** Lula 45,4% vs Flavio Bolsonaro 41,5% (Lula +3,9 p.p.) -> [NUMERO FINAL APOS CORTE DE SABADO].
- **Modelo Oficial Aprovado (w=0.0):** Flavio Bolsonaro 45,9% vs Lula 45,6% (Flavio +0,3 p.p.) -> [NUMERO FINAL APOS CORTE DE SABADO].
- **Sensibilidade com Nanicos (w=0.5):** Flavio Bolsonaro 45,8% vs Lula 45,5% (Flavio +0,3 p.p.) -> [NUMERO FINAL APOS CORTE DE SABADO].

Mecanismo de Moderacao da Margem: O Modelo Oficial eleva a pontuacao de Flavio ao expurgar o vies historico anti-oposicao e expande a votacao dos dois lideres simultaneamente via voto util, comprimindo a diferenca liquida entre ambos. Como a distancia projetada (0,3 p.p.) situa-se amplamente abaixo do Erro Medio Historico da Margem Top-2 (**4,54 p.p.**, n=3) e do Percentil 80 da Margem (**5,16 p.p.**), caracteriza-se tecnicamente que a **diferenca projetada e inferior ao erro historico da margem**, sendo estatisticamente indistinguivel de empate no ruído amostral.

Transparencia Econometrica e Limitacao Honesta (Erro da Margem em 2022):

Em 2022, o M0 Puro previu Lula com 46,88% e Bolsonaro com 40,35% (margem de 6,53 p.p. vs 5,23 p.p. do TSE, gerando erro de **1,29 p.p.**). O Modelo Oficial projetou Bolsonaro em 44,76% (+1,57 p.p. vs TSE) e Lula em 45,67% (-2,76 p.p. vs TSE), resultando em margem de 0,91 p.p. Com isso, o **erro na margem polarizada subiu para 4,32 p.p.** no Modelo Oficial. Conclusao: embora o Modelo Oficial reduza fortemente o erro medio de todos os candidatos da urna (de 0,83 para 0,58 p.p.), ele tende a aproximar excessivamente os lideres em eleicoes de polarizacao atipica. Essa limitacao e documentada com total integridade.

5. Aba 2: Agregados Eleitorais e Contas Formais de Desempate

Tres abordagens concorrentes foram testadas no expanding window: Persistencia (Random Walk), Media Movel e Tendencia Linear.

1. **Abstencao (% sobre Aptos):** Persistencia = 0,9433 | Media Movel = 2,1669 | **Tendencia Linear = 0,3989 p.p.**
 - Conta formal: $\Delta_{bar} = MAE_{Linear} - MAE_{Persist} = -0,5444$ p.p. com $SE(\Delta) = 0,3608$ p.p.
 - Decisao: Como $|\Delta_{bar}| = 0,5444 > SE = 0,3608$, a Tendencia Linear e estatisticamente superior e vence sem necessidade da regra de parcimonia. **Projecao Oficial 2026: 22,3%** sobre aptos.
2. **Votos Brancos (% sobre Comparecimento):** **Persistencia = 0,9867** | Media Movel = 0,9969 | Tendencia Linear = 1,2061 p.p.
 - Conta formal: $\Delta_{bar} = MAE_{Media} - MAE_{Persist} = +0,0103$ p.p. com $SE(\Delta) = 0,3160$ p.p.
 - Decisao: Como $|\Delta_{bar}| = 0,0103 \leq SE = 0,3160$, ha empate tecnico. Pela regra formal de parcimonia, seleciona-se a Persistencia (patamar de 2022). **Projecao Oficial 2026: 1,6%** sobre comparecimento.
3. **Votos Nulos (% sobre Comparecimento):** Persistencia = 1,3167 | **Media Movel = 1,2147** | Tendencia Linear = 1,3989 p.p.
 - Conta formal: $\Delta_{bar} = MAE_{Media} - MAE_{Persist} = -0,1019$ p.p. com $SE(\Delta) = 0,1429$ p.p.
 - Decisao: Como $|\Delta_{bar}| = 0,1019 \leq SE = 0,1429$, a diferenca e inferior a 1 SE (empate estatistico). Pela regra de parcimonia, vence a Persistencia. **Projecao Oficial 2026: 2,8%** sobre comparecimento.

6. Protocolo de Fechamento do Corte de Sabado (Checkpoint 4)

O pipeline processara os dados definitivos no corte de **sabado 03/10/2026 as 20h00**. Pesquisas registradas no PesqEle/TSE com divulgacao programada: **Datafolha** (BR-01708/2026, n=4.006), **Quaest** (BR-02197/2026, n=3.702), **AtlasIntel** (BR-00999/2026, n=5.000), **PoderData** (BR-03519/2026, n=4.000) e **Real Time Big Data** (BR-01068/2026, n=2.000). Caso algum levantamento nao seja publicado ate as 20h00, o motivo sera registrado em reports/checkpoint_4.md e a projecao final utilizara as pesquisas homologadas disponiveis. Os valores finais preencherao os marcadores [NUMERO FINAL] no relatorio e na planilha outputs/previsao_2026.xlsx.

Joao Pedro Valuche
Estatistica e Econometria

Arthur Caron Lyra
Estatistica e Econometria

Lethicia Manfioletti Possamai
Estatistica e Econometria