

DESAFIO DE ESTATÍSTICA E ECONOMETRIA • FGV EPGE

Previsão do 1º turno presidencial de 2026

Relatório técnico completo

João Pedro Valuche de Andrade Pereira • Lethicia Manfioletti Possamai • Arthur Caron Lyra

Horário de corte dos dados: sábado, 03/10/2026, às 20h00 (horário de Brasília). Status: FINAL (pesquisas até 03/10/2026, 20h00).

Este relatório detalha o que a nota metodológica de duas páginas resume: os dados, cada etapa do código, todos os modelos testados, os resultados completos da validação e as limitações. Todos os números vêm do mesmo código que gera a planilha de entrega.

46,1%

Flávio Bolsonaro

45,7%

Lula

2,2%

Augusto Cury

22,3%

Abstenção

1,6%

Branco

2,8%

Nulo

Contents

1	O problema	2
2	Dados	2
3	Pipeline	2
4	Modelos candidatos	3
5	Protocolo de validação	4
6	Resultados da validação	5
7	O modelo final	6
8	Previsão de 2026	7
9	Abstenção, branco e nulo	8
10	Limitações	8
11	Como o projeto foi construído	8
12	Glossário	9
13	Reprodutibilidade	10

1 O problema

Precisamos prever, para o 1º turno de 4 de outubro de 2026, o percentual de votos válidos de cada um dos $K = 12$ candidatos e três agregados: a abstenção (sobre o eleitorado apto) e os votos brancos e nulos (sobre o comparecimento). O erro de uma previsão é o erro absoluto médio sobre todos os candidatos:

$$\text{MAE} = \frac{1}{K} \sum_{i=1}^K |\hat{p}_i - p_i|. \quad (1)$$

Duas consequências guiaram o trabalho. Primeiro, o vencedor importa pouco: errar Lula e Flávio em 2 pontos cada pesa o mesmo que errar quatro candidatos médios em 1 ponto cada. Segundo, os candidatos pequenos contam: com 12 candidatos, um erro de 0,5 ponto em cada um dos sete nanicos soma 3,5 pontos, mais do que um erro grande em um dos líderes. Por isso escolhemos modelos pelo MAE sobre *toda* a urna das eleições passadas, incluindo os candidatos que as pesquisas nem divulgavam.

2 Dados

2.1 Resultados oficiais

Baixamos do Portal de Dados Abertos do TSE a votação por candidato e o detalhe da apuração de 2006, 2010, 2014, 2018 e 2022 e agregamos ao nível nacional. Como teste de sanidade, o código reproduz os números oficiais de 2022 (Lula 48,43%, Bolsonaro 43,20%, abstenção 20,95%) e falha se algum deles divergir.

2.2 Pesquisas históricas

Reunimos 109 pesquisas nacionais estimuladas de 1º turno divulgadas nos 21 dias anteriores a cada eleição, com instituto, datas de campo e divulgação, amostra e contratante. Duas decisões de limpeza:

- o *tracking* diário do Vox Populi em 2010 foi reduzido a rodadas sem sobreposição de amostra, para não contar o mesmo entrevistado várias vezes;
- Ibope e Ipec formam uma única série, já que o Ipec foi criado pela equipe do Ibope.

2.3 Pesquisas de 2026

Usamos somente pesquisas com registro conferido no PesqEle/TSE. Cada número foi transcrito da página original, que guardamos com hash SHA-256; um teste automático confere cada valor transcrito junto ao nome do candidato na página salva. A Tabela 1 lista as pesquisas, em votos totais, como foram divulgadas.

Tabela 1: Pesquisas de 2026 usadas, como divulgadas: % dos votos totais, exceto quando o instituto divulgou os candidatos só em votos válidos (B+N e indecisos aparecem como –). Na média entra a mais recente de cada instituto.

Instituto	Registro TSE	Campo	n	Lula	Flávio	Cury	Caiado	Renan	Zema	B+N	Indec.
Datafolha	BR-00304/2026	22/09 a 24/09	2.002	40	36	5	4	3	1	5	2
PoderData/Aya	BR-01739/2026	20/09 a 23/09	3.000	41	39	6	2	3	1	4	2
Quaest	BR-06520/2026	24/09 a 27/09	2.004	39	34	4	4	3	1	10	5
AtlasIntel	BR-04391/2026	23/09 a 28/09	5.000	45,3	42,2	2	1,8	5,2	0,9	0,9	1,2
Datafolha	BR-08039/2026	28/09 a 01/10	2.506	42	38	4	3	3	1	5	2
Real Time Big Data	BR-09503/2026	26/09 a 30/09	2.000	43	39	3	3	4	1	3	3
PoderData/Aya	BR-03519/2026	30/09 a 02/10	4.000	45	43	4	3	3	1	–	–

3 Pipeline

A Figura 1 mostra o caminho dos dados até a planilha. Cada caixa é uma função testada no repositório; a seguir mostramos versões resumidas do código, sem docstrings e tratamento de casos extremos.




Figura 1: Do dado bruto à previsão. Em vermelho, a etapa que decide o que entra no modelo.

3.1 Conversão para votos válidos

Cada pesquisa divulga intenções x_{ij} em votos totais, incluindo brancos, nulos e indecisos. Convertemos para votos válidos dividindo pela soma dos candidatos:

$$v_{ij} = \frac{x_{ij}}{\sum_{c=1}^K x_{cj}} \times 100. \quad (2)$$

Isso equivale a supor que os indecisos se distribuem como os decididos, a mesma hipótese implícita na apuração do TSE.

```

def converter_para_votos_validos(linha, candidatos):
    intencoes = {c: float(linha.get(c)) if pd.notna(linha.get(c)) else 0.0
                 for c in candidatos}
    soma = sum(intencoes.values()) # brancos, nulos e indecisos ficam fora
    if soma <= 0:
        raise ValueError("Soma das intenções é zero")
    return {c: v / soma * 100.0 for c, v in intencoes.items()}
  
```

3.2 Agregação (M0)

De cada instituto usamos só a pesquisa mais recente dentro da janela, para que institutos com rodadas frequentes não pesem mais que os outros. A previsão base é a média simples entre institutos.

```

def estimar_m0(df_pesquisas, eleicao):
    df = df_pesquisas.copy()
    df["instituto_clean"] = df["instituto"].apply(padronizar_nome_instituto)
    ultimas = (df.sort_values("data_divulgacao", ascending=False)
               .drop_duplicates(subset=["instituto_clean"])) # 1 por instituto
    validos = [converter_pesquisa_validos(r, candidatos) for _, r in ultimas.iterrows()]
    media = {c: np.mean([p[c] for p in validos]) for c in candidatos}
    return renormalizar_votos(media)
  
```

3.3 Arredondamento

A planilha exige uma casa decimal e soma exata de 100,0. Arredondar cada valor separadamente pode dar 99,9 ou 100,1. Usamos o método dos maiores restos: arredondamos todos para baixo e distribuímos os décimos que faltam aos candidatos com as maiores partes descartadas.

```

def maiores_restos(valores, total=100.0, casas=1):
    fator = 10 ** casas
    escalados = [round(v * total / sum(valores) * fator, 10) for v in valores]
    inteiros = [math.floor(s) for s in escalados]
    faltam = round(total * fator) - sum(inteiros)
    ordem = sorted(range(len(valores)), key=lambda i: (-escalados[i] - inteiros[i]), i))
    for i in ordem[:faltam]:
        inteiros[i] += 1 # décimo vai para o maior resto
    return [x / fator for x in inteiros]
  
```

4 Modelos candidatos

Antes de rodar qualquer validação, registramos por escrito quatro modelos base e suas grades de hiperparâmetros.

M0, média simples. $\hat{p}_i = \frac{1}{J} \sum_{j=1}^J v_{ij}$, com J institutos.

M1, recência e amostra. Pesquisas maiores e mais próximas da eleição pesam mais:

$$\hat{p}_i = \frac{\sum_j w_j v_{ij}}{\sum_j w_j}, \quad w_j = \sqrt{N_j} 2^{-\Delta t_j/h}, \quad h \in \{7, 14, 21\} \text{ dias}, \quad (3)$$

em que N_j é a amostra e Δt_j a distância em dias até a véspera. A raiz de N_j vem de o erro amostral cair com $1/\sqrt{N}$.

M2, efeito instituto (house effect). Alguns institutos erram sistematicamente para um lado. Para cada instituto j e bloco político $b \in \{\text{PT, principal adversário, demais}\}$, medimos o desvio médio do instituto em relação à média dos institutos na mesma eleição, $\bar{\beta}_{jb}$, e o encolhemos conforme o número de eleições n_j em que o instituto aparece:

$$\hat{\beta}_{jb} = \frac{n_j}{n_j + k} \bar{\beta}_{jb}, \quad k \in \{1, 3, 10\}, \quad v_{ij}^{\text{corr}} = v_{ij} - \hat{\beta}_{j,b(i)}. \quad (4)$$

Medir o desvio contra a média dos institutos, e não contra a urna, separa o efeito do instituto do erro que todos cometem juntos (tratado na Seção 7).

M3, regressão Ridge. Regressão do resultado de cada candidato sobre a média das pesquisas, a incumbência (candidato ou partido do governo) e a posição nas pesquisas, com penalização $\alpha \|\beta\|_2^2$, $\alpha \in \{0, 1; 1; 10\}$.

5 Protocolo de validação

5.1 Validação temporal

Uma previsão eleitoral só pode usar o passado. Por isso validamos em janela crescente (*expanding window*): cada eleição de teste é prevista usando só as anteriores (Figura 2). Como complemento, reportamos também o *leave-one-election-out* (LOEO), que usa as cinco eleições mas deixa cada uma de fora por vez.




Figura 2: Janela crescente: nenhuma previsão usa informação posterior à eleição prevista. São 21, 39 e 69 pesquisas de treino e 18, 30 e 40 pesquisas de teste.

5.2 Regra de decisão

Com só três eleições de teste, uma diferença pequena de MAE pode ser ruído. Fixamos a regra antes de ver os resultados. Para comparar um modelo mais complexo B com um mais simples A , calculamos a redução do erro em cada eleição, $\Delta_t = \text{MAE}_t^A - \text{MAE}_t^B$, e exigimos

$$\bar{\Delta} > \text{EP}(\Delta) = \frac{s_{\Delta}}{\sqrt{n}}, \quad n = 3. \quad (5)$$

Se a condição não vale, fica o mais simples, na ordem M0, M1, M2, M3. A decisão é sequencial: primeiro escolhemos o modelo base; depois testamos cada ajuste sobre ele, um de cada vez; por fim, o modelo combinado.

```
def calcular_diferenca_e_se(mae_A, mae_B):
    deltas = np.array(mae_A) - np.array(mae_B) # ganho de B sobre A, por eleição
    s_delta = np.std(deltas, ddof=1)
    return deltas.mean(), s_delta / math.sqrt(len(deltas))
```

5.3 Pré-registro

O documento de pré-registro, com os modelos, as grades e a regra acima, foi escrito antes do backtest e recebeu três emendas datadas, todas anteriores à execução da validação: a primeira tratou das datas de divulgação, dos nanicos divulgados de forma agregada, da separação entre instituto e contratante e do teste de sanidade das vésperas; a segunda escreveu as equações, as grades e a regra de empate, e definiu o viés comum, o voto útil e a âncora dos nanicos; a terceira separou o efeito instituto do viés comum, fixou o protocolo sequencial e a tabela de incumbência. Depois de rodar o backtest, nenhum modelo ou hiperparâmetro foi alterado.

6 Resultados da validação

6.1 Etapa 1: modelo base

A Tabela 2 traz todas as configurações. A média simples teve o menor erro em 2014 e 2018 e o menor erro médio. O segundo colocado, M1 com $h = 7$, perde por $\Delta = 0,27$ ponto com $EP = 0,21$: escolhemos o M0.

Tabela 2: Etapa 1: MAE (p.p.) no *expanding window*, todas as configurações.

Modelo	Configuração	2014	2018	2022	Média
M0	média simples	1,33	1,50	0,83	1,22
M1	$h = 7$	1,96	1,73	0,77	1,49
	$h = 14$	2,08	1,85	0,81	1,58
	$h = 21$	2,13	1,89	0,83	1,62
M2	$k = 1$	2,09	1,82	0,92	1,61
	$k = 3$	2,09	1,83	0,85	1,59
	$k = 10$	2,09	1,84	0,82	1,58
M3	$\alpha = 0,1$	2,01	1,89	1,36	1,75
	$\alpha = 1$	1,85	2,02	1,19	1,69
	$\alpha = 10$	1,99	2,13	1,26	1,79




Figura 3: MAE por eleição da melhor configuração de cada modelo e do modelo final. Os modelos mais sofisticados erram mais que a média simples em 2014 e 2018: com poucas eleições para estimar pesos e efeitos, a complexidade extra vira ruído.

6.2 Etapa 2: ajustes sobre o M0

A âncora dos nanicos (mediana histórica dos partidos equivalentes no TSE) não passou na regra: as pesquisas antigas quase nunca divulgavam nanicos individualmente, então não havia como medir o ganho. Fixamos $w = 0$.


O LOEO confirma o resultado: o modelo final tem MAE médio de 1,24 contra 1,45 do M0 e erra menos em quatro das cinco eleições (2006, 2014, 2018 e 2022).

6.3 Erro candidato a candidato

A Figura 4 mostra onde o modelo final ganha e onde perde. Em 2014 ele reduz bastante o erro de Dilma e de Aécio. Em 2018 corrige quase todo o erro de Bolsonaro, mas piora o de Haddad. Em 2022 passa do ponto em Bolsonaro e piora Lula, mas reduz o erro de Tebet e Ciro, e o saldo no MAE ainda é positivo.

Tabela 3: Etapa 2: cada ajuste testado isoladamente sobre o M0 e o modelo combinado.

Configuração	2014	2018	2022	Média	$\bar{\Delta}$	EP	Decisão
M0 (referência)	1,33	1,50	0,83	1,22			
Viés comum, $k_\mu = 1$	1,08	1,43	0,88	1,13	0,09	0,09	passa
Viés comum, $k_\mu = 3$	0,95	1,45	0,71	1,04	0,18	0,10	passa (melhor)
Viés comum, $k_\mu = 10$	1,13	1,48	0,69	1,10	0,12	0,05	passa
Voto útil, $\gamma = 0,25$	1,33	1,48	0,76	1,19	0,03	0,02	passa
Voto útil, $\gamma = 0,5$	1,32	1,46	0,68	1,16	0,07	0,04	passa
Voto útil, $\gamma = 1$	1,31	1,43	0,53	1,09	0,13	0,09	passa (melhor)
Âncora dos nanicos, $w = 0,5$	1,31	1,50	0,84	1,22	0,004	0,007	não passa
Modelo final	0,92	1,39	0,58	0,96	0,26	0,09	adotado

**Figura 4:** Erro dos quatro candidatos mais votados em cada eleição de teste, média simples (cinza) e modelo final (azul).

7 O modelo final

7.1 Viés comum

As pesquisas de véspera não erram ao acaso: nas três eleições de teste, o principal adversário do PT terminou acima da média das pesquisas (Figura 5). Como todos os institutos erraram para o mesmo lado, o efeito instituto do M2 não captura esse erro; é um erro da eleição inteira. Estimamos o viés médio de cada bloco nas eleições de treino e o subtraímos da média de 2026:

$$\hat{\mu}_b = \frac{N}{N + k_\mu} \cdot \frac{1}{N} \sum_{t=1}^N \left(\bar{v}_{b,t}^{\text{pesq}} - v_{b,t}^{\text{TSE}} \right), \quad k_\mu = 3, \quad \hat{p}_i \leftarrow \hat{p}_i - \hat{\mu}_{b(i)}. \quad (6)$$

O fator $N/(N + 3)$ encolhe a correção quando há poucas eleições de treino: com $N = 2$, aplicamos 40% do viés médio; com $N = 5$, 62,5%.

```
def aplicar_ajuste_vies_comum(base_preds, eleicao, eleicoes_treino, k_mu=3.0):
    erros = {"pt": [], "adv": [], "demais": []}
    for t in eleicoes_treino:
        tse = carregar_resultado_tse(t)
        for _, row in obter_pesquisas_eleicao(t).iterrows():
            p = converter_pesquisa_validos(row, HISTORICO_CANDIDATOS[t])
            for c in HISTORICO_CANDIDATOS[t]:
                erros[identificar_bloco(t, c)].append(p[c] - tse[c])
    n = len(eleicoes_treino)
    mu = {b: n / (n + k_mu) * np.mean(e) for b, e in erros.items()}
    ajustado = {c: max(0.0, v - mu[identificar_bloco(eleicao, c)])
                for c, v in base_preds.items()}
    return renormalizar_votos(ajustado)
```

7.2 Voto útil

Na reta final, parte dos eleitores do 3º e do 4º colocados migra para um dos dois primeiros, que têm chance real de ir ao 2º turno. Medimos a perda média $\bar{\delta}$ dos candidatos em 3º e 4º entre a média das pesquisas e a




Figura 5: Erro da média simples das pesquisas de véspera. O principal adversário do PT (Aécio em 2014, Bolsonaro em 2018 e 2022) foi subestimado nas três eleições.

urna nas eleições de treino e a transferimos aos dois primeiros, na proporção das intenções:

$$\hat{p}_{3,4} \leftarrow \hat{p}_{3,4} - \gamma \bar{\delta} \frac{\hat{p}_{3,4}}{\hat{p}_3 + \hat{p}_4}, \quad \hat{p}_{1,2} \leftarrow \hat{p}_{1,2} + \gamma \bar{\delta} \frac{\hat{p}_{1,2}}{\hat{p}_1 + \hat{p}_2}, \quad \gamma = 1. \quad (7)$$

```
transf = gamma * delta_bar
adj[c3] -= transf * base[c3] / (base[c3] + base[c4]) # sai do 3o e 4o
adj[c4] -= transf * base[c4] / (base[c3] + base[c4])
adj[c1] += transf * base[c1] / (base[c1] + base[c2]) # entra no 1o e 2o
adj[c2] += transf * base[c2] / (base[c1] + base[c2])
```

8 Previsão de 2026




Figura 6: Previsão de 2026 para os 12 candidatos.

Tabela 4: Previsão final e decomposição: quanto cada ajuste desloca Lula e Flávio.

Configuração	Lula	Flávio	Lula – Flávio (p.p.)
M0 (média simples)	45,7	41,7	+4,0
M0 + viés comum	44,7	45,0	-0,3
M0 + voto útil	46,8	42,8	+4,0
Modelo final	45,7	46,1	-0,4
Modelo final com âncora dos nanicos ($w = 0,5$)	45,7	46,1	-0,4

A decomposição mostra que o viés comum é o ajuste que mais move a previsão: sozinho, leva Flávio para

perto de Lula. O voto útil puxa votos de Cury, Caiado e Renan para os dois primeiros. A âncora dos nanicos, que ficou de fora pela regra, quase não muda o resultado.

Margem entre os dois primeiros. No backtest, o erro do modelo final na margem entre 1º e 2º colocados foi de 5,72 pontos em 2014, 3,58 em 2018 e 4,32 em 2022 (média de 4,5). A diferença prevista entre Lula e Flávio é bem menor que isso: o modelo não tem resolução para apontar quem termina em primeiro.

Faixas de erro. No backtest, o erro absoluto ficou abaixo de 4,9 pontos em 80% dos casos para os dois primeiros colocados, de 2,5 pontos para o 3º e o 4º e de 0,6 ponto para os demais.

9 Abstenção, brancos e nulos

Para cada agregado comparamos três previsores na mesma janela crescente e com a mesma regra: persistência ($\hat{y}_t = y_{t-1}$), média histórica ($\hat{y}_t = \frac{1}{|T|} \sum_{s \in T} y_s$) e tendência linear (regressão em função do ano). A ordem de simplicidade é persistência, média, tendência.

Tabela 5: Erro absoluto (p.p.) por eleição de teste e decisão.

Variável	Método	2014	2018	2022	Média	Decisão
Abstenção	Persistência	1,27	0,94	0,62	0,94	vence: $\bar{\Delta} = 0,54 > EP = 0,36$
	Média	1,96	2,24	2,30	2,17	
	Tendência	0,10	0,40	0,70	0,40	
Brancos	Persistência	0,71	1,19	1,06	0,99	empate com a média; fica a mais simples
	Média	0,91	0,58	1,50	1,00	
	Tendência	0,31	1,69	1,62	1,21	
Nulos	Persistência	0,29	0,34	3,32	1,32	média ganha 0,10 com EP 0,14: empate
	Média	0,21	0,48	2,96	1,21	
	Tendência	0,46	0,36	3,38	1,40	

Previsões para 2026: abstenção de 22,3% do eleitorado apto, brancos de 1,6% e nulos de 2,8% do comparecimento. A abstenção sobe de forma contínua desde 2006 (16,8%) até 2022 (21,0%), o que explica a vitória da tendência. Brancos e nulos caíram muito em 2022, com a eleição polarizada; a persistência supõe que 2026 se parece mais com 2022 do que com as eleições anteriores.

10 Limitações

- **Três eleições de teste.** Toda a seleção se apoia em $n = 3$. A regra do erro-padrão protege contra parte do sobreajuste, mas não substitui uma amostra maior.
- **O viés comum pode passar do ponto.** Em 2022 ele reduziu o MAE de 0,83 para 0,58, mas levou Bolsonaro a 44,8% contra 43,2% na urna e aumentou o erro da margem de 1,3 para 4,3 pontos. Se o erro das pesquisas em 2026 não seguir o padrão das eleições anteriores, a correção desloca a previsão na direção errada.
- **Blocos políticos.** A correção usa três blocos fixos (PT, principal adversário, demais). Em 2026 o principal adversário é Flávio Bolsonaro, o que supõe que o padrão de 2018 e 2022 se mantém para o mesmo campo político.
- **Nanicos.** Quando nenhuma pesquisa divulga um candidato, a previsão dele é próxima de zero. O erro esperado é pequeno por candidato, mas soma em sete candidatos.

11 Como o projeto foi construído

Organizamos o trabalho em etapas, cada uma com um relatório e uma revisão antes de seguir para a próxima. A regra era simples: nenhuma etapa usa informação que só aparece numa etapa posterior.

Tabela 6: Etapas do projeto.

Quando	Etapas	O que foi feito
02/10, manhã	Entendimento	Leitura das regras, definição da métrica (MAE sobre todos os candidatos), estrutura do código e primeiros testes.
02/10, manhã	Dados do TSE	Resultados de 2006 a 2022 baixados, processados e conferidos contra os números oficiais de 2022. Pesquisas de 2026 transcritas e conferidas no PesqEle.
02/10, início da tarde	Pesquisas históricas e pré-registro	109 pesquisas de véspera compiladas. Modelos, grades e regra de decisão escritos e congelados, com três emendas antes do backtest.
02/10, tarde	Backtest	Validação temporal de todos os modelos e ajustes, LOEO, erro da margem e escolha do modelo final pela regra.
02/10, fim da tarde	Entrega	Planilha com validador, nota metodológica em $\text{\LaTeX}$ com números gerados pelo código e roteiro automático do corte.
03/10	Corte	Transcrição das pesquisas da véspera até 20h00 e geração dos arquivos finais.

11.1 Controles de qualidade

Cada número que entra na previsão passa por pelo menos um controle automático:

- **Transcrição.** Cada pesquisa de 2026 tem a página original salva com hash SHA-256; um teste procura cada número transcrito junto ao nome do candidato na página.
- **Sanidade.** O código reproduz o resultado oficial de 2022 e as pesquisas de véspera do Datafolha em 2014, 2018 e 2022, com tolerância de 1 ponto.
- **Consistência.** Um teste recalcula o MAE candidato a candidato e confere com as tabelas deste relatório.
- **Formato.** Um validador confere as duas abas da planilha, os rótulos, o formato numérico e a soma exata de 100,0.

11.2 O que corrigimos no caminho

As revisões entre etapas encontraram e corrigiram problemas que teriam mudado o resultado:

- a primeira versão do MAE ignorava os candidatos que as pesquisas não divulgavam; passamos a calcular sobre toda a urna, como exige a métrica;
- a média simples de 2022 aparecia com dois valores diferentes em tabelas distintas (Lula 48,32% e 46,88%); unificamos tudo num único script de tabelas, com teste de consistência;
- partidos de 2026 estavam desatualizados (Caiado no PSD, Zema no Novo) e foram alinhados à lista oficial;
- a âncora histórica dos nanicos chegou a ser mantida no modelo apesar de não passar na regra; voltou a $w = 0$;
- o erro-padrão do modelo final estava calculado como 0,04; o valor correto é 0,09 (o modelo continua passando na regra, com redução média de 0,26);
- números de pesquisas sem fonte verificável foram descartados; só ficou o que tem registro no PesqEle e página salva.

12 Glossário

Votos válidos Votos dados a candidatos, excluindo brancos e nulos. É a base do resultado oficial do 1º turno.

MAE Erro absoluto médio: a média, sobre os candidatos, da distância entre previsão e resultado, em pontos percentuais.

House effect Desvio sistemático de um instituto em relação aos demais.

Viés comum Erro que todos os institutos cometem na mesma direção numa eleição.

Voto útil Migração de eleitores de candidatos sem chance de 2º turno para um dos dois primeiros.

Encolhimento Multiplicar uma estimativa por um fator menor que 1 quando há poucas observações, para não reagir demais ao ruído.

Expanding window Validação em que cada eleição é prevista apenas com as eleições anteriores.

LOEO *Leave-one-election-out*: cada eleição é deixada de fora uma vez e prevista com as demais.

Erro-padrão (EP) Medida da incerteza de uma média; aqui, da redução média do MAE entre eleições.

Pré-registro Documento que fixa modelos e regras de decisão antes de ver os resultados da validação.

Maiores restos Método de arredondamento que garante soma exata de 100,0.

13 Reprodutibilidade

O código, os dados, o pré-registro e este relatório estão em <https://github.com/pvaluche/trabalho-econometria-al/tree/entrega-final>. Para reproduzir:

```
git clone https://github.com/pvaluche/trabalho-econometria-al.git
cd trabalho-econometria-al
python -m venv .venv && source .venv/bin/activate
pip install -r requirements.txt
python -m pytest -q                # suíte de testes
python scripts/executar_backtest_oficial.py    # backtest e planilha
python scripts/validar_entrega.py outputs/previsao_2026.xlsx
```

Os testes cobrem a conversão para votos válidos, o arredondamento, o cálculo do MAE, os denominadores do TSE, a agregação por instituto, a reprodução dos resultados de 2022, o formato da planilha, a transcrição das pesquisas de 2026 contra as páginas salvas, os filtros de data das pesquisas e a consistência entre as tabelas deste relatório e o cálculo do MAE.